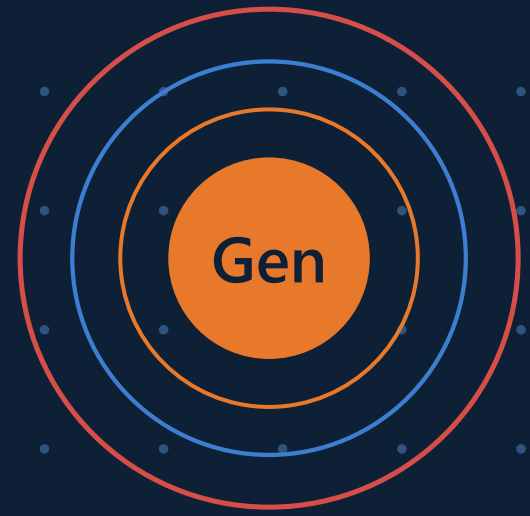
CORPORACIÓN UNIVERSITARIA ADVENTISTA

Facultad de Ciencias Administrativas y Contables

Inteligencia Artificial Generativa



Especialización en Alta Gerencia

Clase 02 · Del motor por dentro al agente que trabaja

Miércoles 5 de agosto de 2026 · 6:30 – 9:30 p. m. · Virtual

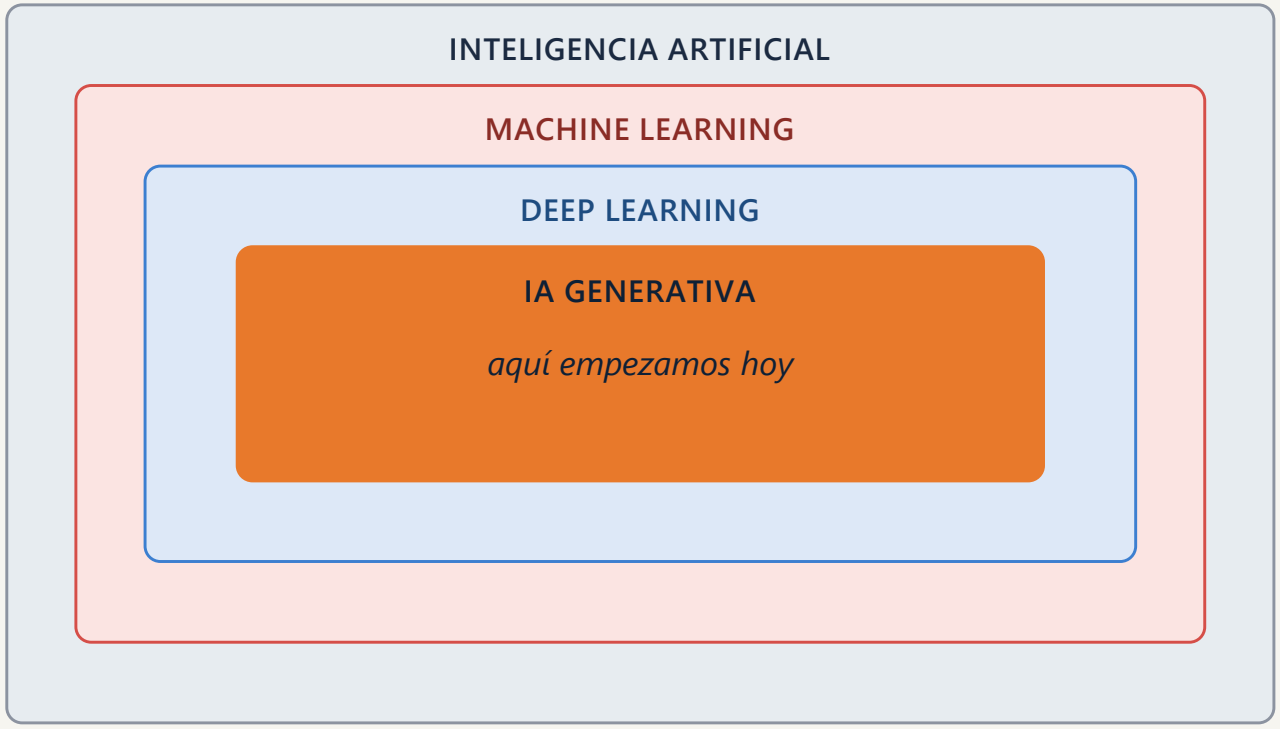
Mg. Alexey David Velásquez Betancourt

MSc. Ingeniería de Inteligencia Artificial

6:35 · 8 min

Empezamos por el centro

La capa más profunda es también la más nueva. Vamos de adentro hacia afuera.



centro ⟶ afuera · lo más nuevo ⟶ lo más viejo

El círculo de la esquina

De aquí en adelante, cada diapositiva le dice en qué capa estamos.

G **IA GENERATIVA**
El motor que escribe, ve y razona

D **DEEP LEARNING**
Las redes neuronales que lo sostienen

M **MACHINE LEARNING**
Aprender de los datos, sin escribir reglas

LA RUTA DE ESTA NOCHE

6:43 · 5 min

Cuatro paradas

01	**EL MOTOR POR DENTRO**	Qué es la IA generativa · token · NLP · Transformer · parámetros	6:48
02	**LOS LÍMITES REALES**	Ventana de contexto · alucinaciones · adulación · cómo se mide	7:35
03	**DE MOTOR A EMPLEADO**	Ojos para leer · manos para actuar · iniciativa propia	8:05
04	**MANOS AL TECLADO**	La terminal · instalar Claude · primer ejercicio real	8:25

Descanso de 15 minutos a las 7:20.

6:48 · 32 min

G

BLOQUE 01 · EL NÚCLEO

El motor por dentro: qué es la IA generativa

LO PRIMERO QUE HAY QUE DESARMAR

No busca. Escribe.

La diferencia con Google no es de tamaño. Es de naturaleza.

UN BUSCADOR	UNA IA GENERATIVA
Tiene guardadas las páginas	No guarda las páginas
Le devuelve las que coinciden	Construye la respuesta palabra por palabra
Si no existe, no le da nada	Si no existe, la inventa igual
Siempre igual ante lo mismo	Puede darle algo distinto cada vez

Esa tercera línea es la que les va a costar plata. Guárdenla.

Adivinando la palabra que sigue

Una sola operación, repetida miles de veces.

«El gerente entró a la sala de ____»



No entiende la frase. Calcula cuál palabra es más probable — y repite.

Porcentajes ilustrativos, para explicar el mecanismo.

El token

La IA no ve palabras ni letras. Ve pedacitos.



8 tokens · 6 palabras — «proveedor» y «venció» se parten en dos

1

UN TOKEN

En inglés, unos 4 caracteres: tres cuartos de palabra.

2

EL ESPAÑOL CUESTA MÁS

Tildes, eñes y palabras largas se parten más veces.

3

SE PAGA POR TOKEN

Es la unidad de la factura. No la palabra, no la página.

4

TODO ES TOKEN

Su Excel, su PDF y su foto terminan convertidos en esto.

DE DÓNDE SALIÓ ESTO

Setenta años enseñándole a leer

Cada etapa resolvió el problema que la anterior no pudo.



REGLAS A MANO

Un humano escribe cada regla del idioma

CONTAR PALABRAS

Estadística: qué palabras aparecen juntas

EMBEDDINGS

Cada palabra, un punto en un mapa de significado

REDES QUE RECUERDAN

Leen en orden, palabra por palabra. Lentas.

TRANSFORMER

Leen todo a la vez y prestan atención

Esto se llama NLP: procesamiento de lenguaje natural.
Enseñarle a una máquina a leer y escribir como nosotros.

CÓMO LUCE POR DENTRO

D

El Transformer

Google, 2017. El artículo que cambió todo: «Attention Is All You Need».

SU TEXTO

«El gerente entró…»

›

TOKENS

Se parte en pedacitos

›

NÚMEROS

Cada token, una lista de números

›

ATENCIÓN

Cada token mira a todos los demás

›

×96 VECES

La misma operación, en capas

›

PROBABILIDAD

La palabra que sigue

Lo que se repite 96 veces no es magia: es la misma multiplicación de números, muchísimas veces.

Sigue siendo una red neuronal. Lo nuevo es cómo lee: todo de una vez, no en fila.

LA IDEA QUE GANÓ

D

Prestar atención

Antes leía en fila y se le olvidaba. Ahora mira todo al mismo tiempo.

«La factura que Flor radicó el lunes todavía no ha sido pagada»

Para entender «pagada», ¿a qué palabra tiene que mirar?



«Pagada» se refiere a la factura, no a Flor ni al lunes. Eso es atención: repartir el peso.

Pesos ilustrativos.

D

¿Qué son «175 mil millones de parámetros»?

No son neuronas. No son datos. No son hechos que sabe.

LO QUE LA GENTE CREE

- ✕ «Son neuronas artificiales»
- ✕ «Son los datos con que lo entrenaron»
- ✕ «Son los hechos que se sabe»
- ✕ «Más parámetros = más inteligente»

LO QUE REALMENTE SON

Los números que gradúan la fuerza de cada conexión de la red.

Como 175 mil millones de perillas de volumen. El entrenamiento fue girarlas una por una hasta que la red acertara.

=

lo que el modelo aprendió

Un parámetro no guarda un dato. Guarda una fuerza. Por eso el modelo no puede citarle su fuente.

PARA LOS QUE QUIEREN EL NÚMERO

D

De dónde salen los 175 mil millones

GPT-3, cuya arquitectura sí es pública. La cuenta cierra.

96	12 288	96	175 000 millones
capas	**de ancho**	**cabezas**	**parámetros**
una encima de otra	números por token	de atención por capa	el resultado

$$12 \times 12\,288^2 \times 96 \text{ capas} \approx 174 \text{ mil millones}$$

Y para que corra: cada mil millones de parámetros pesa unos 2 gigabytes. GPT-3 completo son ~350 GB de memoria de video. Comprimiéndolo a 4 bits baja a ~87 GB. Ahí es donde empieza a ser posible correr un modelo en su propia empresa.

PAUSA

15 minutos

Volvemos a las 7:35. Cuando volvamos: por qué esta cosa se equivoca —y cómo se mide que se equivocó.

7:35 · 30 min

G

BLOQUE 02 · LOS LÍMITES

Por qué se equivoca y cómo saberlo

CUÁNTO PUEDE MIRAR DE UNA VEZ

La ventana de contexto

Todo lo que le quepa en la cabeza al mismo tiempo: su pregunta, sus documentos y todo lo que ya se dijeron.

1 000 000
de tokens

Claude Opus 5
Claude Sonnet 5

200 000
de tokens

Claude Haiku 4.5

Un millón de tokens son unas 750 000 palabras: la Biblia completa, más o menos.

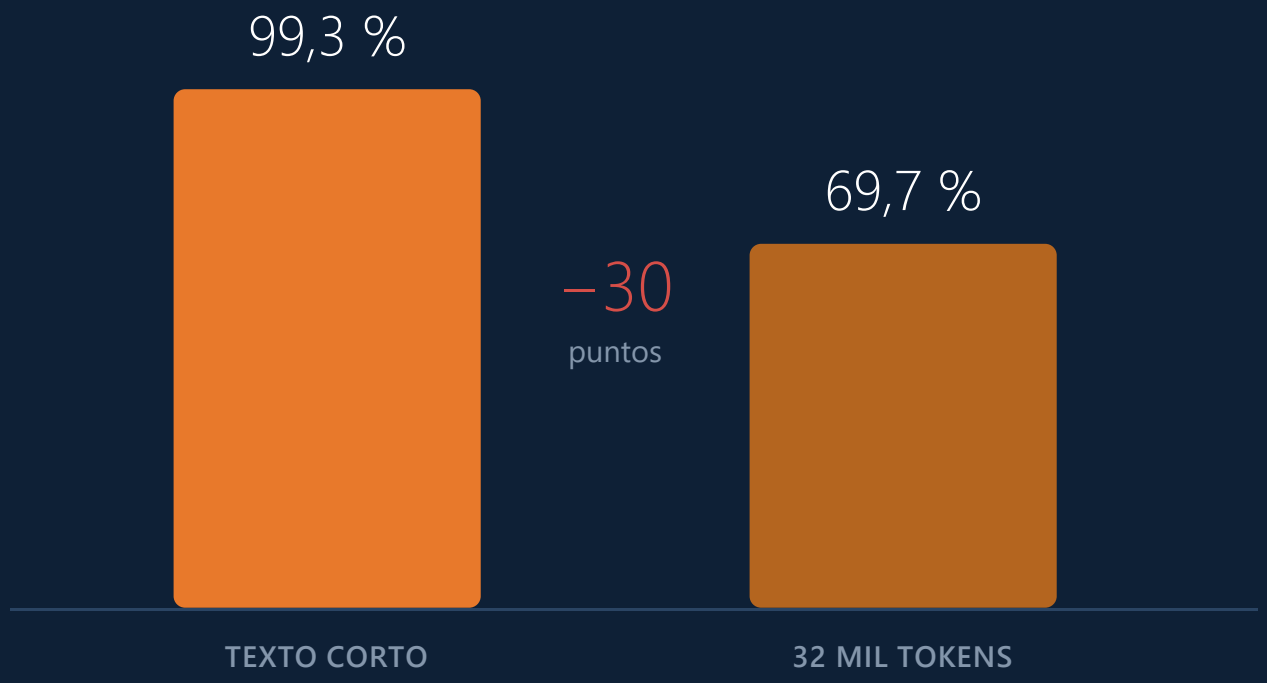
Y aquí está la trampa que casi nadie les va a contar:

que le quepa no significa que lo lea bien todo.

LO QUE SE DETERIORA

Le cabe un millón. No rinde en un millón.

Medido, publicado y reproducible: entre más largo el texto, más falla.



Mismo modelo, misma pregunta. Lo único que cambió fue el largo del texto.

Lo que muestra el estudio

Cae con el largo
El mismo modelo, la misma pregunta: 30 puntos menos.

Un solo distractor daña
Basta un párrafo parecido para que se confunda.

El medio se pierde
Lo del principio y el final sobreviven mejor.

NoLiMa (arXiv:2502.05167) · Chroma Research, «Context Rot», julio de 2025.

G

La aguja en el pajar

El experimento es tan simple que ustedes lo pueden hacer el viernes.

1

SE ESCONDE LA AGUJA

Una frase concreta y verificable:
«la clave de la bodega es 4471».

2

SE ARMA EL PAJAR

Se entierra en un texto larguísimo
que no tiene nada que ver.

3

SE PREGUNTA

«¿Cuál es la clave de la bodega?»
Una sola respuesta correcta.

4

SE REPITE Y SE CUENTA

Cambiando el largo y la posición.
El % de aciertos es la nota.

El eje horizontal de la gráfica anterior es el tamaño del pajar. El vertical, cuántas veces encontró la aguja.

Hágalo con sus propios documentos antes de confiarle un proceso: esconda un dato que usted ya sepa, pregúntelo, y cuente cuántas veces acierta.

Por qué inventa

No es un error de programación. Es cómo está construido.

POR DENTRO

Su comportamiento por defecto es negarse a responder.

Cuando reconoce un nombre, se activa otra señal —«a este lo conozco»— que apaga la negativa.

El problema es cuando reconoce el nombre pero no sabe nada más. Ahí apaga la negativa sin tener la respuesta.

Y HAY UN PISO

Los hechos que aparecieron una sola vez en el entrenamiento no se pueden aprender.

Si el 20 % de los datos que le importan salieron una sola vez, se va a equivocar en por lo menos el 20 %.

Ningún modelo más grande arregla eso. Solo darle la fuente.

En el momento de inventar, por dentro cree que sabe. No hay duda que usted pueda apelar.

Anthropic, «Tracing the thoughts of a large language model», marzo de 2025.

Lo entrenamos para que adivine

Los exámenes con que se califican los modelos no dan ni un punto por «no sé».

MODELO	ACIERTA	SE EQUIVOCA	DICE «NO SÉ»
Modelo que se abstiene	22 %	**26 %**	52 %
Modelo que siempre responde	24 %	**75 %**	1 %

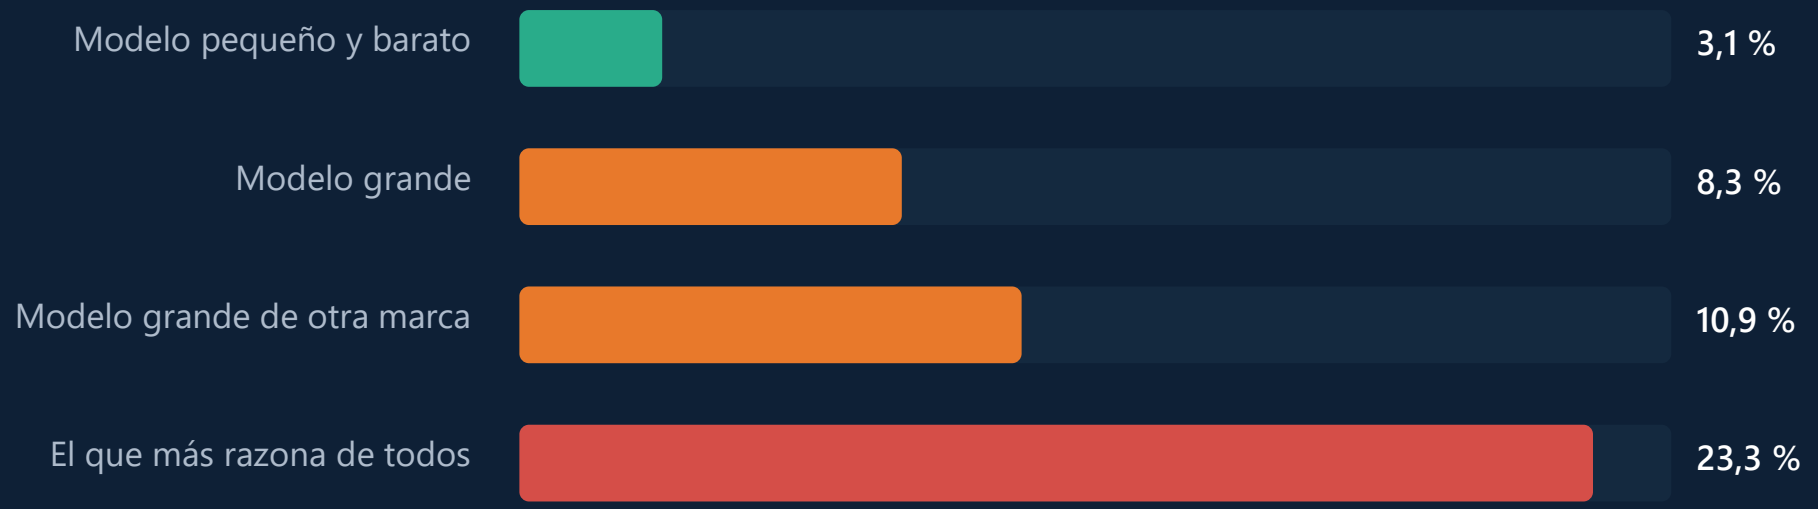
El de abajo gana por 2 puntos en el ranking — y se equivoca tres veces más.

Es el que la lista premia. Y es el que usted no quiere.

Igual que un estudiante en un examen sin penalización: si no sabe, marca cualquiera. Nunca deja en blanco.

También falla con el papel en la mano

Resumir un documento que usted mismo le entregó. Porcentaje de resúmenes con algo que el documento no dice.



El modelo que más razona es el que más se inventa cosas sobre su documento.

Razonar de más es elaborar de más. Y elaborando se cuela lo que no estaba.

Vectara Hallucination Leaderboard, 11 de mayo de 2026 · 7 700 documentos.

Errores

El modelo «siempre le daba la razón a la persona». Tiene nombre, tiene medida y tiene papers.

95 %

PREFIERE ADULAR

El sistema que califica las respuestas prefiere la aduladora sobre la cierta.

98 %

SE RETRACTA

De las veces cede si usted le dice «¿está seguro?» — incluso teniendo razón.

1 de 7

LO DAÑA

Veces que presionarlo convierte una respuesta correcta en una incorrecta.

78 %

NO VUELVE

Una vez que cede, se queda cedido el resto de la conversación.

No es un defecto del entrenamiento. Es el entrenamiento funcionando bien sobre el objetivo equivocado.

Lo premiamos por «¿le gustó la respuesta?». Y a la gente le gusta que le den la razón.

Nunca le pregunte «¿está seguro?». Pregúntele «muéstreme de dónde lo sacó».

LO QUE ESTO CUESTA EN LA VIDA REAL

No son anécdotas de internet

Firmas grandes, clientes públicos y consecuencias con fecha.

A$ 97 000

DEVUELTOS

Deloitte Australia, octubre de 2025

Un informe para el gobierno con una cita judicial inventada y papers que no existen.

US$ 5 000

DE SANCIÓN

Mata v. Avianca, Nueva York, junio de 2023

Seis fallos judiciales inventados, atribuidos a jueces reales que existen.

US$ 110 000

DE SANCIÓN

Couvrette v. Wisnovsky, Oregón

Quince casos falsos y ocho citas fabricadas. Agravante: intentaron taparlo al corregir.

Ninguno era un estudiante haciendo trampa. Eran profesionales entregando trabajo.

G

Tres defensas que puede usar mañana

Ninguna elimina el problema. Las tres lo reducen mucho.

1

PREGÚNTELO TRES VECES

La misma pregunta en tres chats separados. Si le da tres respuestas distintas, no sabe.

2

PIDA LA FUENTE Y ÁBRALA

«Muéstreme el link de dónde lo sacó.» Una cita que usted no abrió es decoración.

3

DELE PERMISO DE NO SABER

«Responde solo si estás más de 75 % seguro. Si no, di que no sabes y qué necesitarías para saberlo.»

Lo que NO funciona: decirle «no alucines».

El incentivo está en el entrenamiento, no en su instrucción. Y por dentro, él cree que sabe.

La número 1 es un método publicado, sin las matemáticas. Le toma 90 segundos y es gratis.

Los exámenes de la IA

Cuando lea que un modelo «es el más inteligente», esto es lo que midieron.

CONOCIMIENTO

Preguntas de doctorado en física, química y biología

Opción múltiple.
Se cuenta el % correcto.

PROGRAMACIÓN

Errores reales de software libre, con su solución conocida

Corre las pruebas.
Pasa o no pasa.

RAZONAMIENTO

Acertijos visuales que no estaban en internet

Se diseñan nuevos para que no los sepa.

SABER QUE NO SABE

6 000 preguntas de negocio, salud, derecho e ingeniería

+1 si acierta, −1 si falla,
0 si dice «no sé».

La cuarta es la que a ustedes les importa, y es la más nueva.

En su lanzamiento, de todos los modelos del mundo, solo tres sacaron más de cero.

Los modelos de hoy

Precios por millón de tokens. Un millón de tokens son unas 750 000 palabras.

MODELO	VENTANA	ENTRADA	SALIDA	
Claude Haiku 4.5	200 mil	US$ 1	US$ 5	*el más barato*
Claude Sonnet 5	1 millón	US$ 2	US$ 10	*promoción*
Claude Opus 5	1 millón	US$ 5	US$ 25	*el equilibrado*
Claude Fable 5	1 millón	US$ 10	US$ 50	*el más capaz*

Hoy vamos a usar Sonnet 5.

Le cabe un millón de tokens, sigue instrucciones bien, y esta noche cuesta la mitad de lo normal.

8:05 · 20 min

G

BLOQUE 03 · LA ESCALERA

De motor a empleado: qué se le atornilla encima

Cuatro escalones

El motor es el mismo. Lo que cambia es lo que puede alcanzar.

EL MOTOR

Solo texto.
Usted escribe, él responde.

+ OJOS

Lee su PDF, su Excel,
su foto, su plano.

+ MANOS

Usa herramientas:
buscar, calcular, escribir
archivos.

+ INICIATIVA

Decide él los pasos,
los ejecuta y verifica.

Todo lo que ustedes van a usar en serio vive en los dos últimos escalones.

Un chat es el primero. Claude Code —lo que instalamos hoy— es el cuarto.

ESCALÓN 2

G

Ojos: que lea lo que usted ya tiene

PDF

DOCUMENTOS

Contratos, pliegos, facturas.
Lo parte en pedazos y los lee.

XLS

HOJAS DE CÁLCULO

Ve filas y columnas.
Ojo: las celdas combinadas lo confunden.

IMG

FOTOS Y PLANOS

Un plano, un tablero, una captura.
Hoy lee texto dentro de la imagen.

SCN

ESCANEADOS

Aquí está la trampa: si es una foto
del papel, puede no leerse.

Todo esto termina convertido en tokens. La foto también.

Por eso una imagen consume tanto: una sola puede costar como varias páginas de texto.

Katerine: el plano. Flor: el pliego. Ingrith: el extracto bancario. Osorio: el contrato del municipio.

ESCALÓN 3

Manos: que use herramientas

El modelo no calcula ni busca. Pero puede pedirle a algo que lo haga.

USTED PIDE

«¿Cuánto llevamos facturado este mes?»

›

ÉL DECIDE

«Necesito abrir el archivo de ventas»

›

LA HERRAMIENTA CORRE

El computador lee el archivo de verdad

›

ÉL RESPONDE

Con el número real, no con uno inventado

Esta es la diferencia entre «me suena que fueron unos 40 millones» y «fueron 41 350 200».

Con herramientas deja de adivinar el dato y va a buscarlo.

Es la mejor defensa práctica contra las alucinaciones: si el número lo saca de su archivo, no se lo puede inventar.

ESCALÓN 4

Iniciativa: el agente

Deja de contestarle preguntas y empieza a terminarle tareas.

UN CHAT

Usted pregunta, él responde

Un paso por cada mensaje suyo

Usted arma la secuencia

Si se equivoca, usted lo nota

Termina cuando usted se va

UN AGENTE

Usted da el objetivo, él hace el plan

Muchos pasos sin preguntarle

Él arma la secuencia

Revisa su propio trabajo y corrige

Termina cuando la tarea está hecha

Y esto es exactamente lo que vamos a instalar ahora en su computador.

8:25 · 60 min

BLOQUE 04 · TALLER

Manos al teclado

LO PRIMERO QUE HAY QUE PERDERLE EL MIEDO

La terminal

La pantalla negra donde se le habla al computador escribiendo.

```
PS C:\Users\Alexey>
claude

* Bienvenido a Claude Code
```

Se escribe una orden, se aprieta Enter, el computador responde. Nada más. No hay nada que se pueda romper por escribir.

SIN VENTANAS

No hay botones ni menús.
Solo texto.

MÁS PODEROSA

Todo lo que hace el mouse,
y mucho que no.

ES LA CASA DE LA IA

Aquí es donde la IA
puede trabajar sola.

EL VOCABULARIO MÍNIMO

Tres palabras y ya está

Con esto sobra para toda la noche.

1

POWERSHELL

La terminal de Windows.
Se abre con la tecla Windows
y escribiendo «powershell».

2

UN COMANDO

Una orden escrita.
Siempre: qué hacer,
sobre qué cosa.

3

LA CARPETA ACTUAL

Dónde está usted parado.
Es lo que la IA va a poder ver.
«cd» sirve para moverse.

```
cd Documentos
```

«métete en la carpeta Documentos» — dos palabras: la orden y sobre qué.

Eso es todo el vocabulario. Lo demás se lo va a pedir a la IA en español.

AHORA SÍ

8:40 · 30 min

Cuatro pasos y queda instalado

Copien y peguen. No lo escriban a mano.

1 **ABRIR POWERSHELL**

Tecla Windows, escribir «powershell», Enter.

2 **PEGAR ESTO Y ENTER**

El instalador se descarga y se instala solo.

```
irm https://claude.ai/install.ps1 | iex
```

3 **CERRAR Y VOLVER A ABRIR**

Sin esto, el paso 4 va a decir que no lo conoce.

4 **COMPROBAR Y ENTRAR**

Debe responder con un número de versión.

```
claude --version
```

Después de esto: escriban «claude», aprueben la clave que les pasé, y ya están dentro.

CUANDO ALGO FALLA

Y va a fallar. Está previsto.

Busque su mensaje de error en la columna izquierda.

LO QUE VE	POR QUÉ	QUÉ HACE
«irm no se reconoce»	Está en CMD, no en PowerShell	Abra PowerShell y repita
«claude no se reconoce»	No cerró y volvió a abrir	Cierre TODA la ventana y abra otra
«no se pueden ejecutar scripts»	Windows bloquea por seguridad	`Set-ExecutionPolicy RemoteSigned -Scope CurrentUser`
Error de certificado o 403	Antivirus o red de la empresa	Pruebe: winget install Anthropic.ClaudeCode
No encuentra sus archivos	Arrancó en la carpeta equivocada	Salga, haga cd a su carpeta, vuelva a entrar

Si en cinco minutos no arranca: júntese con un compañero y sigan en un solo computador. No se pierda la clase por la instalación.

9:10 · 15 min

Póngalo a trabajar con lo suyo

Con la carpeta de documentos que trajo hoy. Tres órdenes, en español.

1 QUE MIRE

«Mirá qué archivos hay en esta carpeta y decime de qué se trata cada uno.»

Lo obliga a leer antes de opinar.

2 QUE EXTRAIGA

«Del archivo de ventas, decime el total por región y los tres productos que más dejaron.»

Aquí usa herramientas: el número sale del archivo.

3 QUE PRODUZCA

«Con eso armame un resumen de una página para presentarle a mi jefe.»

De datos a entregable, sin que usted lo escriba.

Va a pedirle permiso antes de abrir cosas. Léalo. Ese es el punto: usted sigue mandando.

PARA LA PRÓXIMA

9:25 · 5 min

Lo que queda de tarea

1

UNA TAREA COMPLETA

Escoja una de las cinco tareas repetitivas que trajo y hágala entera con Claude Code.

2

ANOTE LOS TIEMPOS

Cuánto se demoraba antes.
Cuánto se demoró ahora.
Ese número es su proyecto.

3

ANOTE DÓNDE FALLÓ

Qué le inventó, qué no entendió, qué tuvo que corregirle.
Eso vale más que lo que salió bien.

La próxima clase: cómo ve la IA sus datos.

Por qué una tabla bien hecha vale más que un modelo más grande.

Traiga el archivo con el que trabajó — bueno o malo. Con eso arrancamos.