CORPORACIÓN UNIVERSITARIA ADVENTISTA

Facultad de Ciencias Administrativas y Contables

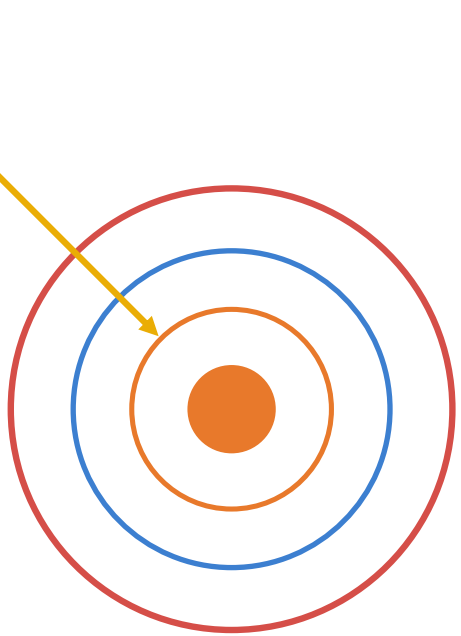
# Machine Learning 1

## Especialización en Alta Gerencia

Clase 04 · Diplomado en Inteligencia Artificial

Miércoles 26 de agosto de 2026 · 6:30 – 9:30 p. m. · Virtual

*hoy entramos así*



**Mg. Alexey David Velásquez Betancurt**

MSc. Ingeniería de Inteligencia Artificial

6:30 · 10 min

# Agenda de la clase

Primero el proyecto de grado; después, la máquina por dentro.

| | | | |
|---|---|---|---|
| 6:40 | **Proyecto de grado** | Entregas, fechas, porcentajes, documento y taller de hoy | |
| 7:05 | **Machine Learning** | Arquitecturas y algoritmos · métricas · pipeline · librerías | M |
| 7:55 | **Descanso** | 15 minutos | |
| 8:10 | **Deep Learning** | Tipos de modelos · pipeline de entrenamiento | D |
| 8:25 | **Transformers** | La arquitectura de los LLM actuales | G |
| 8:35 | **Hugging Face** | Modelos preentrenados, listos para usar | G |
| 8:45 | **Taller** | Su token de Hugging Face · Cloudflare · conectar el aula | |
| 9:20 | **Cierre** | Próxima clase: cómo se entrenan los modelos | |

6:40 · 25 min

BLOQUE 1 · 6:40 – 7:05

# Proyecto de grado



# Entregas, fechas y porcentajes

Cada entrega cierra a las 11:59 p. m. del día indicado. La fecha oficial es la de Moodle.

| ENTREGA 1 | ENTREGA 2 | ENTREGA 3 | ENTREGA 4 | SUSTENTACIÓN |
|---|---|---|---|---|
| 20 % | 20 % | 20 % | 40 % | |
| MIÉ 2 SEP | MIÉ 23 SEP | MIÉ 21 OCT | JUE 5 NOV | JUE 12 NOV |
| *semana del 31 de agosto al 4 de septiembre* | *semana del 21 – 25 de septiembre* | *semana del 19 – 23 de octubre* | *semana del 2 – 6 de noviembre* | ante jurados |
| Plan de trabajo con visto bueno | Avance según el plan | Avance según el plan | Documento final y sustentación | |

**Entrega individual en Moodle · Equipos de mínimo 3 personas · Proyecto en empresa: Convenio de Cooperación Académica**

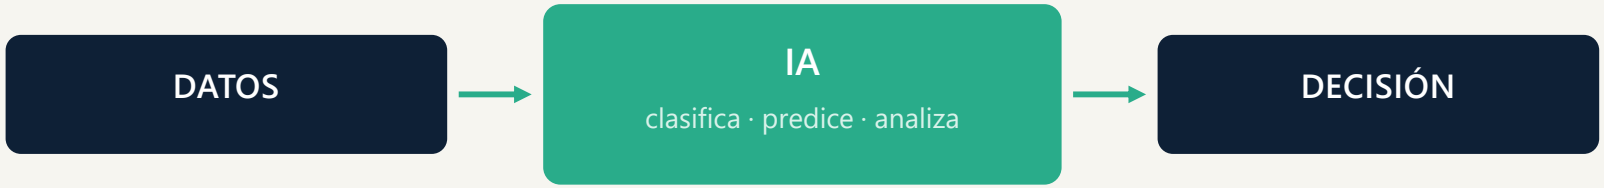
# Requisito: la IA dentro del pipeline

Un trabajo hecho con ayuda de IA no es un trabajo de IA. El criterio es dónde queda la IA.

✕ NO CUENTA




✓ SÍ CUENTA




**La prueba del borrado: si se retira la IA y el proceso sigue funcionando igual, no es un proyecto de IA.**

# Estructura del documento

La misma estructura de principio a fin. La Entrega 1 llega hasta la metodología.

## ENTREGA 1

*el plan de trabajo*

1. Resumen (abstract)
2. Planteamiento del problema
3. Objetivos del proyecto
4. Descripción del proceso metodológico
5. Referencias APA 7

*Sin resultados y sin conclusiones: todavía no existen.*

## ENTREGAS 2 · 3 · 4

*el documento que crece*

1. Resumen (abstract)
2. Planteamiento del problema
3. Objetivos del proyecto
4. Metodología
5. Resultados
6. Conclusiones
7. Referencias APA 7

*La sección metodológica cambia de nombre: ya no es plan, es lo que se hizo.*

**APA 7 · cada referencia se abre y se comprueba · Word o PDF en Moodle · los límites de cada sección están en la guía del aula**

PROYECTO DE GRADO

# Taller de hoy

Dos cosas para llevarse funcionando esta noche. La Entrega 1 se sube el miércoles 2 de septiembre.

1

### SU TOKEN DE HUGGING FACE

Crearlo y guardarlo en el .env para que su Claude pueda descargar modelos del Hub.

**huggingface.co/settings/tokens**

token de tipo Read · va al .env

2

### CONECTAR EL AULA

Clonar el aula y dejar que su Claude evalúe la idea de proyecto contra los criterios de la Entrega 1.

**Clase_04_Conectar_Aula_IA.html**

conexión única de 5 minutos

**La Entrega 1 no es de hoy: cierra el miércoles 2 de septiembre a las 11:59 p. m.**

Plan de trabajo del equipo, con visto bueno previo del docente · se sube individualmente a Moodle · 20 %

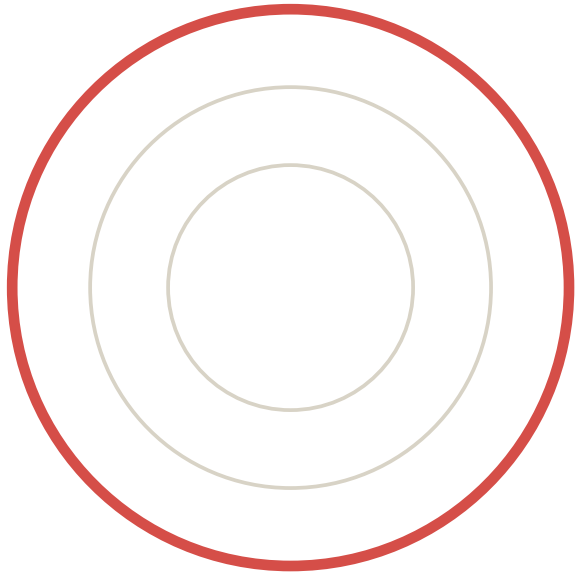
Las dos cosas se hacen en el taller de las 8:45 · se retoman en el cierre

M

7:05 · 50 min

BLOQUE 2 · 7:05 – 7:55

# Machine Learning

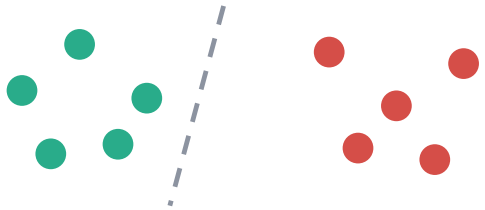


# Tipos de Machine Learning

Supervised learning, unsupervised learning y reinforcement learning.

## SUPERVISADO

*supervised learning*



dos clases etiquetadas + frontera

- Features (X) → variable objetivo: target (y)
- Requiere datos etiquetados (labels)
- Tareas: classification, regression
- Classification: binary o multicategory
- Métricas: Accuracy, Precision, Recall, F1

## NO SUPERVISADO

*unsupervised learning*

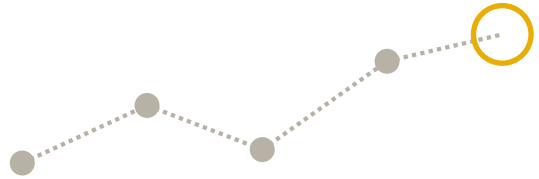


clusters descubiertos en los datos

- Solo features (X), sin target
- Tarea principal: clustering
- Algoritmos: K-Means, DBSCAN, PCA
- Métrica: Silhouette Score

## POR REFUERZO

*reinforcement learning*



ensayo y error hacia la recompensa

- Agente + entorno + recompensa
- Algoritmos: Q-Learning, PPO
- Usos: robótica, juegos, RLHF
- Fuera del alcance del curso

# Arquitecturas del Machine Learning supervisado

De los Linear Models a los Transformers. Hacia arriba: más accuracy, menos interpretabilidad.

**5 · Transformers** — *attention (2017)*
- **BERT** — texto · clasificación, NER
- **Vision Transformer** — ViT · imagen
- **Whisper** — audio → texto (STT)

**4 · Neural Networks** — *redes neuronales · deep learning*
- **MLP** — tabular · perceptrón multicapa
- **CNN** — imagen · ResNet, YOLO
- **RNN · LSTM** — secuencia y series de tiempo

**3 · Tree-based & Ensemble** — *bagging, boosting y stacking*
- **Decision Tree** — reglas if / then · auditable
- **Bagging · Random Forest** — árboles en paralelo, y votan
- **Boosting · XGBoost** — en fila, corrigiendo al anterior

**2 · Instance & Kernel Based** — *por vecino cercano y por frontera*
- **k-Nearest Neighbors** — k-NN · por vecindad
- **Support Vector Machine** — SVM · frontera óptima
- **Naive Bayes** — probabilístico · texto

**1 · Linear Models** — *modelos lineales · el baseline*
- **Linear Regression** — predice un número
- **Logistic Regression** — clasificación binaria
- **Ridge · Lasso** — regularización

# Arquitecturas del Machine Learning no supervisado

Solo features (X), sin target. Hacia arriba: de Clustering a Self-supervised Learning.

**5 · Self-supervised Learning** — *el preentrenamiento de los LLM*
- Word2Vec · Embeddings — texto → vectores
- Masked LM — tapar palabras · BERT
- CLIP — imagen + texto, mismo vector

**4 · Autoencoders** — *el target es la propia entrada (X → X)*
- Autoencoder (AE) — comprime y reconstruye
- Denoising AE — quita el ruido
- Variational AE (VAE) — genera datos nuevos

**3 · Anomaly Detection** — *detección de anomalías*
- Isolation Forest — aísla lo raro
- One-Class SVM — frontera de lo normal
- Apriori — association rules

**2 · Dimensionality Reduction** — *reducción de dimensionalidad*
- PCA — componentes principales
- t-SNE — visualizar en 2D
- UMAP — visualizar · más rápido

**1 · Clustering** — *agrupar por parecido*
- K-Means — usted define k
- DBSCAN — densidad · detecta ruido
- Hierarchical Clustering — dendrograma

# Métricas de clasificación

De dónde salen todas: la confusion matrix. El ejemplo: 1.000 facturas, 100 impagas.

| | LO QUE PREDIJO EL MODELO: SÍ | LO QUE PREDIJO EL MODELO: NO |
|---|---|---|
| REAL: SÍ | TP — 88 — acertó: no pagó | FN — 12 — se le escapó |
| REAL: NO | FP — 9 — falsa alarma | TN — 891 — acertó: sí pagó |

**Accuracy** `(TP + TN) / total` = 97,9 %

*¿cuántas acertó en total?*

**Precision** `TP / (TP + FP)` = 90,7 %

*de las que dije SÍ, ¿cuántas eran?*

**Recall** `TP / (TP + FN)` = 88,0 %

*de todas las que eran SÍ, ¿cuántas encontré?*

**F1 Score** `2 · (P · R) / (P + R)` = 89,3 %

*el equilibrio entre las dos anteriores*

Con clases desbalanceadas la Accuracy engaña: decir «todas pagan» ya da 90 % en este ejemplo

# Otras métricas de evaluación

Las que usan los que saben: para clases desbalanceadas y para predecir números.

## CLASSIFICATION

*cuando las clases están desbalanceadas*

| | |
|---|---|
| **ROC-AUC** | 0,5 = azar · 1,0 = perfecto |
| **PR-AUC** | average precision · mejor si el SÍ es raro |
| **MCC** | Matthews · −1 a 1 · la más honesta |
| **Balanced Accuracy** | promedio del recall de cada clase |
| **Cohen's Kappa** | descuenta los aciertos por azar |
| **Log Loss** | castiga la confianza mal puesta |

## REGRESSION

*cuando el modelo predice un número*

| | |
|---|---|
| **RMSE** | root mean squared error · castiga los errores grandes |
| **MAE** | mean absolute error · el más fácil de explicar |
| **MAPE** | el error en % · ojo si hay valores cerca de cero |
| **$R^2$** | qué proporción de la variación explica el modelo |
| **MSE** | el que minimiza el entrenamiento por dentro |
| **SMAPE** | la versión simétrica del MAPE, para forecasting |

Regla dura: con clases desbalanceadas se reporta PR-AUC o MCC, nunca Accuracy sola

# Métricas del Machine Learning no supervisado

Sin etiquetas no hay Accuracy: se mide la forma de los grupos y el error de reconstrucción.

## CLUSTERING

*sin etiquetas · métricas internas*

**Silhouette Score**
−1 a 1 · sobre 0,5 es razonable

**Davies-Bouldin Index**
menor es mejor

**Calinski-Harabasz Index**
mayor es mejor

**Inertia · elbow method**
para elegir el k

## SI HAY ETIQUETAS

*métricas externas, para comparar*

**Adjusted Rand Index**
ARI · coincidencia con los grupos reales

**Normalized Mutual Info.**
NMI · cuánta información comparten

**Homogeneity · Completeness**
el par que arma el V-measure

**Confusion matrix**
solo si se puede mapear cluster → clase

## REDUCCIÓN Y ANOMALÍAS

*PCA y autoencoders*

**Explained variance ratio**
cuánta información guarda cada componente

**Reconstruction error**
el error de volver a armar el dato

**Umbral (threshold)**
por encima del umbral: anomalía

**Precision / Recall**
si después hay casos confirmados

El k de K-Means se elige con Silhouette y el método del codo · el umbral del autoencoder, con el error de reconstrucción

# Pipeline de entrenamiento de Machine Learning

El orden importa: el split va ANTES del preprocesamiento, o hay data leakage.



# Librerías de Machine Learning y Deep Learning

Con qué se hace cada cosa. Todas son de Python, todas gratis, y su Claude las va a nombrar.

## MACHINE LEARNING CLÁSICO

*tablas, filas y columnas*

**`scikit-learn`**
el estándar: modelos, pipelines y métricas

**`XGBoost · LightGBM · CatBoost`**
gradient boosting, el estado del arte en tablas

**`PyCaret`**
AutoML: compara 15 modelos en tres líneas

**`statsmodels · Prophet`**
estadística y series de tiempo

**`pandas · NumPy`**
cargar y manipular los datos

**`SHAP · imbalanced-learn`**
interpretabilidad y clases desbalanceadas

## DEEP LEARNING

*redes neuronales, imagen, audio y texto*

**`PyTorch`**
el estándar de facto hoy

**`TensorFlow · Keras`**
la alternativa, con mucho legado en producción

**`transformers (Hugging Face)`**
modelos preentrenados de texto, audio e imagen

**`diffusers`**
generación de imagen: Stable Diffusion, FLUX

**`Ultralytics YOLO · timm`**
visión: detección y clasificación

**`librosa · OpenCV`**
audio y visión clásica

Todas se instalan con pip · en Google Colab ya vienen scikit-learn, pandas, PyTorch y transformers

7:55 · 15 min

DESCANSO

# 15 minutos

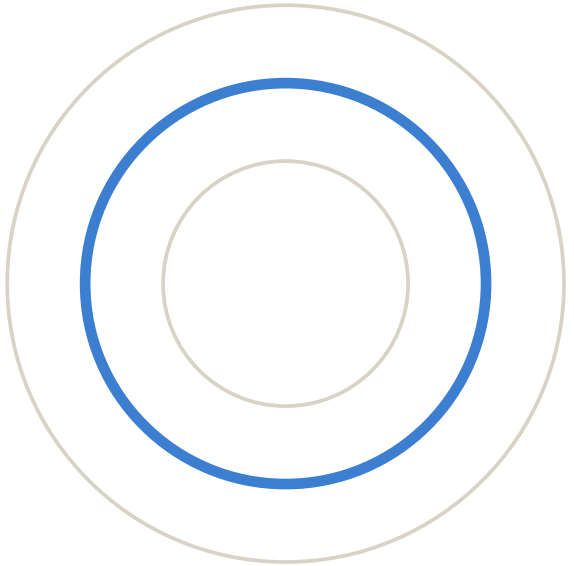


D

8:10 · 15 min

BLOQUE 3 · 8:10 – 8:25

# Deep Learning



D

# Tipos de modelos de Deep Learning

Cada aplicación tiene su arquitectura. Los nombres que van a encontrar.

### CNN

`convolutional neural network`

Imágenes: clasificar, detectar objetos.



### RNN · LSTM

`recurrent neural network`

Secuencias: audio, series de tiempo.



### TRANSFORMER

`self-attention`

Texto y multimodal: los LLM actuales.



### DIFFUSION

`diffusion models`

Generación de imagen y video: FLUX, SD, Sora.



### GAN

`generative adversarial network`

Generación de imagen de la era pre-diffusion.



### AUTOENCODER

`encoder – decoder`

Compresión y detección de anomalías.



Hoy se miran por dentro dos: CNN y Autoencoder · el Transformer tiene bloque propio

D

# Pipeline de entrenamiento de Deep Learning

El mismo proceso del Machine Learning, más lo que aquí se ajusta a mano: capas, neuronas y activaciones.

## 1 ARQUITECTURA

*cuántas capas y de qué tipo*

Capas (depth) y neuronas por capa (width)

Dense · fully connected
Conv2D · Pooling
LSTM · GRU · Attention
Dropout · BatchNorm
Embedding · Flatten

## 2 ACTIVACIONES

*qué deja pasar cada neurona*

ReLU · capas ocultas
GELU · Transformers
LeakyReLU · Tanh

Salida según la tarea:
Sigmoid · binaria
Softmax · multiclase
Linear · regresión

## 3 COMPILACIÓN

*qué se minimiza y con qué ritmo*

Loss function:
Binary Crossentropy
Categorical Crossentropy
MSE · regresión

Optimizer: Adam · AdamW
Learning rate
Backpropagation

## 4 ENTRENAMIENTO

*el ensayo y error costoso*

Epochs · pasadas completas
Batch size
Validation split

Early stopping
Regularización · Dropout
GPU / TPU
Fine-tuning

RESULTADO: la curva de loss de train vs. validation dice si quedó bien entrenado · el modelo se guarda en .pt · .keras · SafeTensors

Overfitting, underfitting y cómo leer esa curva: Clase 05

G

8:25 · 10 min

BLOQUE 4 · 8:25 – 8:35

# Transformers



# El Transformer

Vaswani et al. (2017), «Attention Is All You Need»: la arquitectura de los LLM actuales.

## ENTIENDE

`encoder`

Lee un texto y lo convierte en significado medible.

Clasificar, buscar, medir sentimiento. Ej.: BERT.

## GENERA

`decoder`

Escribe lo que sigue, token por token.

Redactar, razonar, conversar. Ej.: GPT, Claude, Llama.

## TRANSFORMA

`encoder + decoder`

Entra un formato, sale otro.

Traducir, transcribir audio. Ej.: Whisper, traductores.

Mecanismo central: self-attention — cada token decide a qué otros tokens mirar

# Del Transformer a los LLM

La misma arquitectura de 2017, escalada en datos y parámetros.

**2017**
**Transformer**

**2018**
**BERT · GPT**

**2020**
**GPT-3**
175 B parámetros: emerge la conversación

**2022**
**ChatGPT**
el LLM llega al público general

**2024**
**Multimodales**
texto, imagen y audio juntos

**2026**
**Agentes**
razonan y ejecutan (la Clase 03)

G

8:35 · 15 min

BLOQUE 5 · 8:35 – 8:45

# Hugging Face

# Modelos preentrenados en Hugging Face

Seis tareas resueltas con modelos abiertos · repos verificados a 19-ago-2026.

### SPEECH → TEXT

`whisper-large-v3-turbo`

Transcribir consultas, reuniones, llamadas.



### TEXT → SPEECH

`Kokoro-82M · español`

Audioguías, líneas de atención, locuciones.



### TEXT → IMAGE

`Z-Image-Turbo · FLUX`

Piezas de marketing, catálogos, renders.



### IMAGE → TEXT (OCR)

`Qwen3-VL · GLM-OCR`

Leer facturas, planos, fotos de obra.



### TRANSLATION

`MADLAD-400`

419 idiomas. Atender clientes de afuera.



### SENTIMENT ANALYSIS

`robertuito · español`

PQRS y reseñas en español, a escala.



Licencias: MIT y Apache-2.0 permiten uso comercial · CC-BY-NC no. El catálogo del aula trae la de cada modelo.

8:45 · 35 min

BLOQUE 6 · 8:45 – 9:20 · TALLER

# Hugging Face y Cloudflare



TALLER

# El token de Hugging Face

La llave personal para que su Claude descargue y use modelos del Hub.

1

### CUENTA DE HF

Creada en la Clase 03, en huggingface.co.

2

### CREAR EL TOKEN

Settings → Access Tokens → Create new token (Read).

3

### GUARDARLO EN .ENV

El archivo de secretos que montamos en la Clase 03.

4

### SU CLAUDE LO USA

Descarga y ejecuta modelos con la CLI hf o por API.

```
hf auth login --token hf_........
hf auth whoami   →   Login successful · su_usuario
```

Guía completa en el aula: Clase_03_Configurar_HuggingFace.html

TALLER

# Cómo usar un modelo de Hugging Face

El pipeline para modelos ya entrenados: de la task al modelo dentro de su proceso.

1
**DEFINIR LA TASK**
speech-to-text, OCR, sentiment, translation…

2
**ELEGIR EL MODELO**
En el Hub: filtrar por task, licencia y descargas.

3
**AUTENTICARSE**
El token de HF, guardado en el .env.

4
**CARGAR Y PROBAR**
Su Claude lo ejecuta, o la Inference API.

5
**INTEGRAR**
El modelo queda dentro del proceso del negocio.

```
from transformers import pipeline
p = pipeline('automatic-speech-recognition', model='openai/whisper-small')
p('consulta.mp3')   →   'paciente refiere dolor desde el lunes…'
```

Este código lo ejecuta su Claude con el token del .env · el catálogo del aula trae los modelos verificados

TALLER

# Cloudflare Workers AI

La otra infraestructura: modelos abiertos por API, sin servidor propio.

### WORKERS AI

Modelos abiertos por API en la red de Cloudflare · 10.000 neurons gratis por día.

### AI GATEWAY

Mide, cachea y pone tope en USD al gasto en APIs de IA (Anthropic, OpenAI, HF…) · núcleo gratis.

### AI SEARCH

Buscador con IA sobre sus documentos · beta abierta: 20.000 consultas gratis al mes.

### MCP OFICIAL

mcp.cloudflare.com: su Claude administra todo esto conversando.

```
@cf/openai/whisper-large-v3-turbo      speech → text
@cf/deepgram/aura-2-es                 text → speech · voces en español
@cf/black-forest-labs/flux-1-schnell   text → image
```

Prueba sin código: playground.ai.cloudflare.com · Hugging Face es el catálogo; Cloudflare, una infraestructura

TALLER

# El aula conectada

Repositorio del curso en GitHub, leído por el Claude de cada estudiante.

**EL AULA**

`github.com/Alexey0424/Aula_IA_UNAC`

- Guías y diapositivas rayadas
- Notebooks plantilla
- Criterios de las 4 entregas
- Referencias verificadas
- Instrucciones para su Claude




**USTEDES**

*«Revisa mi plan de trabajo contra los criterios»*

*«¿Qué modelo le sirve a mi proyecto?»*

*«¿Esta idea pasa la prueba del borrado?»*

Conexión única de 5 minutos, con la guía del aula · actualizaciones con /actualizar-curso

CIERRE

9:20 · 10 min

# Cierre

Lo que quedó abierto hoy y con qué se sigue.

### ARQUITECTURAS DE ML

supervised y unsupervised,
de los Linear Models a los Transformers

### DEEP LEARNING

redes neuronales, CNN, autoencoders
y la arquitectura Transformer

### MODELOS PREENTRENADOS

Hugging Face y Cloudflare,
con su token y su Claude

## Próxima clase: Machine Learning 2 — cómo se entrenan los modelos

Pipeline de entrenamiento · overfitting · métricas e interpretación · taller en Colab · asesoría por equipos

**Lo de hoy queda funcionando · la Entrega 1 se sube el miércoles 2 de septiembre, 11:59 p. m.**

Del taller: su token de Hugging Face en el .env · el aula conectada a su Claude

# Referencias

Talaei Khoei, T., & Kaabouch, N. (2023). Machine learning: Models, challenges, and research directions. Future Internet, 15(10), 332. https://doi.org/10.3390/fi15100332

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30. https://arxiv.org/abs/1706.03762

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

*Las métricas y las etapas del pipeline siguen la documentación oficial de scikit-learn (model evaluation y compose.Pipeline).*