CORPORACIÓN UNIVERSITARIA ADVENTISTA

Facultad de Ciencias Administrativas y Contables

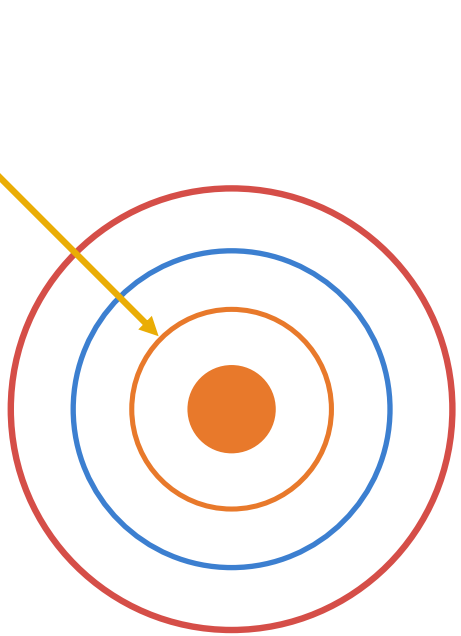
Machine Learning 1

Especialización en Alta Gerencia

Clase 04 · Diplomado en Inteligencia Artificial

Miércoles 26 de agosto de 2026 · 6:30 – 9:30 p. m. · Virtual

hoy entramos así



Mg. Alexey David Velásquez Betancurt

MSc. Ingeniería de Inteligencia Artificial

6:30 · 10 min

Agenda de la clase

Primero el proyecto de grado; después, la máquina por dentro.

6:40	**Proyecto de grado**	Entregas, fechas, porcentajes, documento y taller de hoy	
7:05	**Machine Learning**	Arquitecturas y algoritmos · métricas · pipeline · librerías	M
7:55	**Descanso**	15 minutos	
8:10	**Deep Learning**	Tipos de modelos · pipeline de entrenamiento	D
8:25	**Transformers**	La arquitectura de los LLM actuales	G
8:35	**Hugging Face**	Modelos preentrenados, listos para usar	G
8:45	**Taller**	Su token de Hugging Face · Cloudflare · conectar el aula	
9:20	**Cierre**	Próxima clase: cómo se entrenan los modelos	

6:40 · 25 min

BLOQUE 1 · 6:40 – 7:05

Proyecto de grado



Entregas, fechas y porcentajes

Cada entrega cierra a las 11:59 p. m. del día indicado. La fecha oficial es la de Moodle.

ENTREGA 1	ENTREGA 2	ENTREGA 3	ENTREGA 4	SUSTENTACIÓN
20 %	20 %	20 %	40 %	
MIÉ 2 SEP	MIÉ 23 SEP	MIÉ 21 OCT	JUE 5 NOV	JUE 12 NOV
semana del 31 de agosto al 4 de septiembre	*semana del 21 – 25 de septiembre*	*semana del 19 – 23 de octubre*	*semana del 2 – 6 de noviembre*	ante jurados
Plan de trabajo con visto bueno	Avance según el plan	Avance según el plan	Documento final y sustentación	

Entrega individual en Moodle · Equipos de mínimo 3 personas · Proyecto en empresa: Convenio de Cooperación Académica

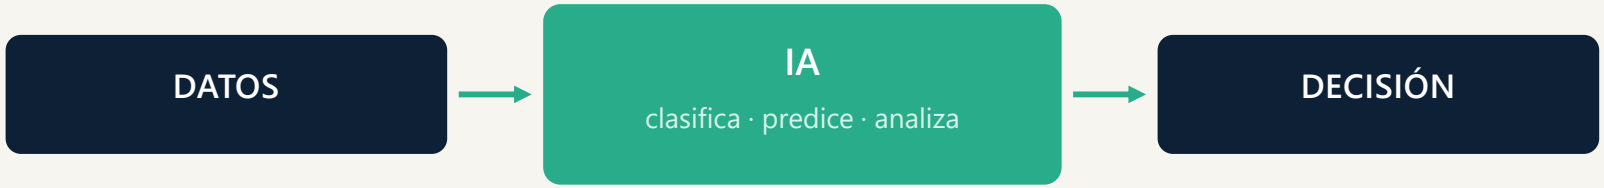
Requisito: la IA dentro del pipeline

Un trabajo hecho con ayuda de IA no es un trabajo de IA. El criterio es dónde queda la IA.

✕ NO CUENTA



✓ SÍ CUENTA



La prueba del borrado: si se retira la IA y el proceso sigue funcionando igual, no es un proyecto de IA.

Estructura del documento

La misma estructura de principio a fin. La Entrega 1 llega hasta la metodología.

ENTREGA 1

el plan de trabajo

1. Resumen (abstract)
2. Planteamiento del problema
3. Objetivos del proyecto
4. Descripción del proceso metodológico
5. Referencias APA 7

Sin resultados y sin conclusiones: todavía no existen.

ENTREGAS 2 · 3 · 4

el documento que crece

1. Resumen (abstract)
2. Planteamiento del problema
3. Objetivos del proyecto
4. Metodología
5. Resultados
6. Conclusiones
7. Referencias APA 7

La sección metodológica cambia de nombre: ya no es plan, es lo que se hizo.

APA 7 · cada referencia se abre y se comprueba · Word o PDF en Moodle · los límites de cada sección están en la guía del aula

PROYECTO DE GRADO

Taller de hoy

Dos cosas para llevarse funcionando esta noche. La Entrega 1 se sube el miércoles 2 de septiembre.

1

SU TOKEN DE HUGGING FACE

Crearlo y guardarlo en el .env para que su Claude pueda descargar modelos del Hub.

huggingface.co/settings/tokens

token de tipo Read · va al .env

2

CONECTAR EL AULA

Clonar el aula y dejar que su Claude evalúe la idea de proyecto contra los criterios de la Entrega 1.

Clase_04_Conectar_Aula_IA.html

conexión única de 5 minutos

La Entrega 1 no es de hoy: cierra el miércoles 2 de septiembre a las 11:59 p. m.

Plan de trabajo del equipo, con visto bueno previo del docente · se sube individualmente a Moodle · 20 %

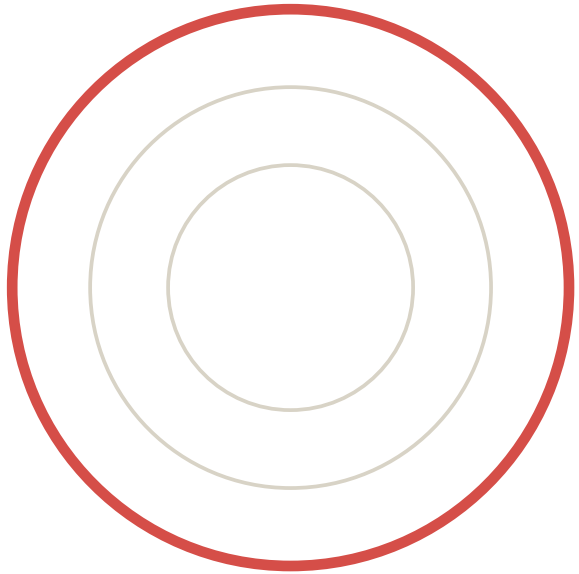
Las dos cosas se hacen en el taller de las 8:45 · se retoman en el cierre

M

7:05 · 50 min

BLOQUE 2 · 7:05 – 7:55

Machine Learning

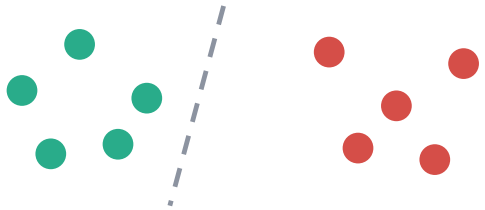


Tipos de Machine Learning

Supervised learning, unsupervised learning y reinforcement learning.

SUPERVISADO

supervised learning



dos clases etiquetadas + frontera

- Features (X) → variable objetivo: target (y)
- Requiere datos etiquetados (labels)
- Tareas: classification, regression
- Classification: binary o multicategory
- Métricas: Accuracy, Precision, Recall, F1

NO SUPERVISADO

unsupervised learning

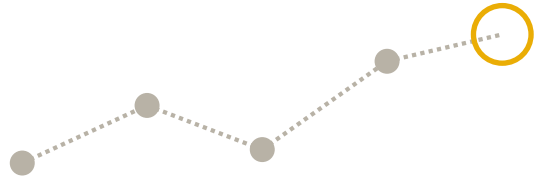


clusters descubiertos en los datos

- Solo features (X), sin target
- Tarea principal: clustering
- Algoritmos: K-Means, DBSCAN, PCA
- Métrica: Silhouette Score

POR REFUERZO

reinforcement learning



ensayo y error hacia la recompensa

- Agente + entorno + recompensa
- Algoritmos: Q-Learning, PPO
- Usos: robótica, juegos, RLHF
- Fuera del alcance del curso

Arquitecturas del Machine Learning supervisado

De los Linear Models a los Transformers. Hacia arriba: más accuracy, menos interpretabilidad.

5 · Transformers — *attention (2017)*
- **BERT** — texto · clasificación, NER
- **Vision Transformer** — ViT · imagen
- **Whisper** — audio → texto (STT)

4 · Neural Networks — *redes neuronales · deep learning*
- **MLP** — tabular · perceptrón multicapa
- **CNN** — imagen · ResNet, YOLO
- **RNN · LSTM** — secuencia y series de tiempo

3 · Tree-based & Ensemble — *bagging, boosting y stacking*
- **Decision Tree** — reglas if / then · auditable
- **Bagging · Random Forest** — árboles en paralelo, y votan
- **Boosting · XGBoost** — en fila, corrigiendo al anterior

2 · Instance & Kernel Based — *por vecino cercano y por frontera*
- **k-Nearest Neighbors** — k-NN · por vecindad
- **Support Vector Machine** — SVM · frontera óptima
- **Naive Bayes** — probabilístico · texto

1 · Linear Models — *modelos lineales · el baseline*
- **Linear Regression** — predice un número
- **Logistic Regression** — clasificación binaria
- **Ridge · Lasso** — regularización

Arquitecturas del Machine Learning no supervisado

Solo features (X), sin target. Hacia arriba: de Clustering a Self-supervised Learning.

5 · Self-supervised Learning — *el preentrenamiento de los LLM*
- Word2Vec · Embeddings — texto → vectores
- Masked LM — tapar palabras · BERT
- CLIP — imagen + texto, mismo vector

4 · Autoencoders — *el target es la propia entrada (X → X)*
- Autoencoder (AE) — comprime y reconstruye
- Denoising AE — quita el ruido
- Variational AE (VAE) — genera datos nuevos

3 · Anomaly Detection — *detección de anomalías*
- Isolation Forest — aísla lo raro
- One-Class SVM — frontera de lo normal
- Apriori — association rules

2 · Dimensionality Reduction — *reducción de dimensionalidad*
- PCA — componentes principales
- t-SNE — visualizar en 2D
- UMAP — visualizar · más rápido

1 · Clustering — *agrupar por parecido*
- K-Means — usted define k
- DBSCAN — densidad · detecta ruido
- Hierarchical Clustering — dendrograma

Métricas de clasificación

De dónde salen todas: la confusion matrix. El ejemplo: 1.000 facturas, 100 impagas.

	LO QUE PREDIJO EL MODELO: SÍ	LO QUE PREDIJO EL MODELO: NO
REAL: SÍ	TP — 88 — acertó: no pagó	FN — 12 — se le escapó
REAL: NO	FP — 9 — falsa alarma	TN — 891 — acertó: sí pagó

Accuracy `(TP + TN) / total` = 97,9 %

¿cuántas acertó en total?

Precision `TP / (TP + FP)` = 90,7 %

de las que dije SÍ, ¿cuántas eran?

Recall `TP / (TP + FN)` = 88,0 %

de todas las que eran SÍ, ¿cuántas encontré?

F1 Score `2 · (P · R) / (P + R)` = 89,3 %

el equilibrio entre las dos anteriores

Con clases desbalanceadas la Accuracy engaña: decir «todas pagan» ya da 90 % en este ejemplo

Otras métricas de evaluación

Las que usan los que saben: para clases desbalanceadas y para predecir números.

CLASSIFICATION

cuando las clases están desbalanceadas

ROC-AUC	0,5 = azar · 1,0 = perfecto
PR-AUC	average precision · mejor si el SÍ es raro
MCC	Matthews · −1 a 1 · la más honesta
Balanced Accuracy	promedio del recall de cada clase
Cohen's Kappa	descuenta los aciertos por azar
Log Loss	castiga la confianza mal puesta

REGRESSION

cuando el modelo predice un número

RMSE	root mean squared error · castiga los errores grandes
MAE	mean absolute error · el más fácil de explicar
MAPE	el error en % · ojo si hay valores cerca de cero
R^2	qué proporción de la variación explica el modelo
MSE	el que minimiza el entrenamiento por dentro
SMAPE	la versión simétrica del MAPE, para forecasting

Regla dura: con clases desbalanceadas se reporta PR-AUC o MCC, nunca Accuracy sola

Métricas del Machine Learning no supervisado

Sin etiquetas no hay Accuracy: se mide la forma de los grupos y el error de reconstrucción.

CLUSTERING

sin etiquetas · métricas internas

Silhouette Score
−1 a 1 · sobre 0,5 es razonable

Davies-Bouldin Index
menor es mejor

Calinski-Harabasz Index
mayor es mejor

Inertia · elbow method
para elegir el k

SI HAY ETIQUETAS

métricas externas, para comparar

Adjusted Rand Index
ARI · coincidencia con los grupos reales

Normalized Mutual Info.
NMI · cuánta información comparten

Homogeneity · Completeness
el par que arma el V-measure

Confusion matrix
solo si se puede mapear cluster → clase

REDUCCIÓN Y ANOMALÍAS

PCA y autoencoders

Explained variance ratio
cuánta información guarda cada componente

Reconstruction error
el error de volver a armar el dato

Umbral (threshold)
por encima del umbral: anomalía

Precision / Recall
si después hay casos confirmados

El k de K-Means se elige con Silhouette y el método del codo · el umbral del autoencoder, con el error de reconstrucción

Pipeline de entrenamiento de Machine Learning

El orden importa: el split va ANTES del preprocesamiento, o hay data leakage.



Librerías de Machine Learning y Deep Learning

Con qué se hace cada cosa. Todas son de Python, todas gratis, y su Claude las va a nombrar.

MACHINE LEARNING CLÁSICO

tablas, filas y columnas

`scikit-learn`
el estándar: modelos, pipelines y métricas

`XGBoost · LightGBM · CatBoost`
gradient boosting, el estado del arte en tablas

`PyCaret`
AutoML: compara 15 modelos en tres líneas

`statsmodels · Prophet`
estadística y series de tiempo

`pandas · NumPy`
cargar y manipular los datos

`SHAP · imbalanced-learn`
interpretabilidad y clases desbalanceadas

DEEP LEARNING

redes neuronales, imagen, audio y texto

`PyTorch`
el estándar de facto hoy

`TensorFlow · Keras`
la alternativa, con mucho legado en producción

`transformers (Hugging Face)`
modelos preentrenados de texto, audio e imagen

`diffusers`
generación de imagen: Stable Diffusion, FLUX

`Ultralytics YOLO · timm`
visión: detección y clasificación

`librosa · OpenCV`
audio y visión clásica

Todas se instalan con pip · en Google Colab ya vienen scikit-learn, pandas, PyTorch y transformers

7:55 · 15 min

DESCANSO

15 minutos

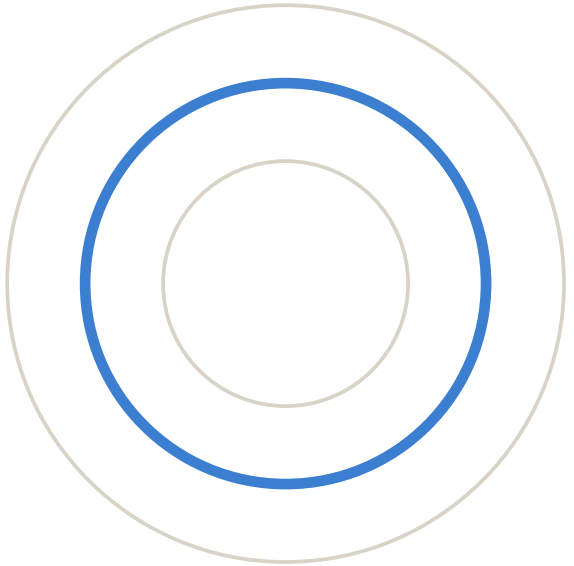


D

8:10 · 15 min

BLOQUE 3 · 8:10 – 8:25

Deep Learning



D

Tipos de modelos de Deep Learning

Cada aplicación tiene su arquitectura. Los nombres que van a encontrar.

CNN

`convolutional neural network`

Imágenes: clasificar, detectar objetos.



RNN · LSTM

`recurrent neural network`

Secuencias: audio, series de tiempo.



TRANSFORMER

`self-attention`

Texto y multimodal: los LLM actuales.



DIFFUSION

`diffusion models`

Generación de imagen y video: FLUX, SD, Sora.



GAN

`generative adversarial network`

Generación de imagen de la era pre-diffusion.



AUTOENCODER

`encoder – decoder`

Compresión y detección de anomalías.



Hoy se miran por dentro dos: CNN y Autoencoder · el Transformer tiene bloque propio

D

Pipeline de entrenamiento de Deep Learning

El mismo proceso del Machine Learning, más lo que aquí se ajusta a mano: capas, neuronas y activaciones.

1 ARQUITECTURA

cuántas capas y de qué tipo

Capas (depth) y neuronas por capa (width)

Dense · fully connected
Conv2D · Pooling
LSTM · GRU · Attention
Dropout · BatchNorm
Embedding · Flatten

2 ACTIVACIONES

qué deja pasar cada neurona

ReLU · capas ocultas
GELU · Transformers
LeakyReLU · Tanh

Salida según la tarea:
Sigmoid · binaria
Softmax · multiclase
Linear · regresión

3 COMPILACIÓN

qué se minimiza y con qué ritmo

Loss function:
Binary Crossentropy
Categorical Crossentropy
MSE · regresión

Optimizer: Adam · AdamW
Learning rate
Backpropagation

4 ENTRENAMIENTO

el ensayo y error costoso

Epochs · pasadas completas
Batch size
Validation split

Early stopping
Regularización · Dropout
GPU / TPU
Fine-tuning

RESULTADO: la curva de loss de train vs. validation dice si quedó bien entrenado · el modelo se guarda en .pt · .keras · SafeTensors

Overfitting, underfitting y cómo leer esa curva: Clase 05

G

8:25 · 10 min

BLOQUE 4 · 8:25 – 8:35

Transformers



El Transformer

Vaswani et al. (2017), «Attention Is All You Need»: la arquitectura de los LLM actuales.

ENTIENDE

`encoder`

Lee un texto y lo convierte en significado medible.

Clasificar, buscar, medir sentimiento. Ej.: BERT.

GENERA

`decoder`

Escribe lo que sigue, token por token.

Redactar, razonar, conversar. Ej.: GPT, Claude, Llama.

TRANSFORMA

`encoder + decoder`

Entra un formato, sale otro.

Traducir, transcribir audio. Ej.: Whisper, traductores.

Mecanismo central: self-attention — cada token decide a qué otros tokens mirar

Del Transformer a los LLM

La misma arquitectura de 2017, escalada en datos y parámetros.

2017
Transformer

2018
BERT · GPT

2020
GPT-3
175 B parámetros: emerge la conversación

2022
ChatGPT
el LLM llega al público general

2024
Multimodales
texto, imagen y audio juntos

2026
Agentes
razonan y ejecutan (la Clase 03)

G

8:35 · 15 min

BLOQUE 5 · 8:35 – 8:45

Hugging Face

Modelos preentrenados en Hugging Face

Seis tareas resueltas con modelos abiertos · repos verificados a 19-ago-2026.

SPEECH → TEXT

`whisper-large-v3-turbo`

Transcribir consultas, reuniones, llamadas.



TEXT → SPEECH

`Kokoro-82M · español`

Audioguías, líneas de atención, locuciones.



TEXT → IMAGE

`Z-Image-Turbo · FLUX`

Piezas de marketing, catálogos, renders.



IMAGE → TEXT (OCR)

`Qwen3-VL · GLM-OCR`

Leer facturas, planos, fotos de obra.



TRANSLATION

`MADLAD-400`

419 idiomas. Atender clientes de afuera.



SENTIMENT ANALYSIS

`robertuito · español`

PQRS y reseñas en español, a escala.



Licencias: MIT y Apache-2.0 permiten uso comercial · CC-BY-NC no. El catálogo del aula trae la de cada modelo.

8:45 · 35 min

BLOQUE 6 · 8:45 – 9:20 · TALLER

Hugging Face y Cloudflare



TALLER

El token de Hugging Face

La llave personal para que su Claude descargue y use modelos del Hub.

1

CUENTA DE HF

Creada en la Clase 03, en huggingface.co.

2

CREAR EL TOKEN

Settings → Access Tokens → Create new token (Read).

3

GUARDARLO EN .ENV

El archivo de secretos que montamos en la Clase 03.

4

SU CLAUDE LO USA

Descarga y ejecuta modelos con la CLI hf o por API.

```
hf auth login --token hf_........
hf auth whoami   →   Login successful · su_usuario
```

Guía completa en el aula: Clase_03_Configurar_HuggingFace.html

TALLER

Cómo usar un modelo de Hugging Face

El pipeline para modelos ya entrenados: de la task al modelo dentro de su proceso.

1
DEFINIR LA TASK
speech-to-text, OCR, sentiment, translation…

2
ELEGIR EL MODELO
En el Hub: filtrar por task, licencia y descargas.

3
AUTENTICARSE
El token de HF, guardado en el .env.

4
CARGAR Y PROBAR
Su Claude lo ejecuta, o la Inference API.

5
INTEGRAR
El modelo queda dentro del proceso del negocio.

```
from transformers import pipeline
p = pipeline('automatic-speech-recognition', model='openai/whisper-small')
p('consulta.mp3')   →   'paciente refiere dolor desde el lunes…'
```

Este código lo ejecuta su Claude con el token del .env · el catálogo del aula trae los modelos verificados

TALLER

Cloudflare Workers AI

La otra infraestructura: modelos abiertos por API, sin servidor propio.

WORKERS AI

Modelos abiertos por API en la red de Cloudflare · 10.000 neurons gratis por día.

AI GATEWAY

Mide, cachea y pone tope en USD al gasto en APIs de IA (Anthropic, OpenAI, HF…) · núcleo gratis.

AI SEARCH

Buscador con IA sobre sus documentos · beta abierta: 20.000 consultas gratis al mes.

MCP OFICIAL

mcp.cloudflare.com: su Claude administra todo esto conversando.

```
@cf/openai/whisper-large-v3-turbo      speech → text
@cf/deepgram/aura-2-es                 text → speech · voces en español
@cf/black-forest-labs/flux-1-schnell   text → image
```

Prueba sin código: playground.ai.cloudflare.com · Hugging Face es el catálogo; Cloudflare, una infraestructura

TALLER

El aula conectada

Repositorio del curso en GitHub, leído por el Claude de cada estudiante.

EL AULA

`github.com/Alexey0424/Aula_IA_UNAC`

- Guías y diapositivas rayadas
- Notebooks plantilla
- Criterios de las 4 entregas
- Referencias verificadas
- Instrucciones para su Claude

`/actualizar-curso`



USTEDES

«Revisa mi plan de trabajo contra los criterios»

«¿Qué modelo le sirve a mi proyecto?»

«¿Esta idea pasa la prueba del borrado?»

LO QUE SE LE ESCRIBE AL CLAUDE, UNA SOLA VEZ, DENTRO DE LA CARPETA C:\Curso_IA_UNAC

```
Clona el repositorio https://github.com/Alexey0424/Aula_IA_UNAC dentro de esta carpeta
y muéstrame qué archivos quedaron.
```

CIERRE

9:20 · 10 min

Cierre

Lo que quedó abierto hoy y con qué se sigue.

ARQUITECTURAS DE ML

supervised y unsupervised,
de los Linear Models a los Transformers

DEEP LEARNING

redes neuronales, CNN, autoencoders
y la arquitectura Transformer

MODELOS PREENTRENADOS

Hugging Face y Cloudflare,
con su token y su Claude

Próxima clase: Machine Learning 2 — cómo se entrenan los modelos

Pipeline de entrenamiento · overfitting · métricas e interpretación · taller en Colab · asesoría por equipos

Lo de hoy queda funcionando · la Entrega 1 se sube el miércoles 2 de septiembre, 11:59 p. m.

Del taller: su token de Hugging Face en el .env · el aula conectada a su Claude

Referencias

Talaei Khoei, T., & Kaabouch, N. (2023). Machine learning: Models, challenges, and research directions. Future Internet, 15(10), 332. https://doi.org/10.3390/fi15100332

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30. https://arxiv.org/abs/1706.03762

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

Las métricas y las etapas del pipeline siguen la documentación oficial de scikit-learn (model evaluation y compose.Pipeline).